


支持向量机

1. 线性分类器



二分类模型, 基本模型是定义在特征空间上的间隔最大的分类器. 学习策略是间隔最大化

用一条直线将黑点和白点分开, 可以有无数条
令黑色的点标签为-1, 白色的点标签为1



直线为 $f(x) = w^T x + b$

x 的维度为 n 时, $f(x)$ 表示 $n-1$ 维超平面.

符号函数
$$\text{sign}(x) = \begin{cases} -1, & x < 0 \\ 0, & x = 0 \\ 1, & x > 0 \end{cases}$$


如何确定一条最优的直线?

让这条直线到给定样本中最近的点最远.



直观上来讲, 分隔的间隔越大越好.

上图中被圈出来的点即为支撑向量 个数可以大于2



classifier boundary 是 $f(\vec{x})$

plus plane 和 minus plane 是支撑向量所在的平面
之间的距离便是要求最大化的分隔间隔

支撑向量的表达式为 $y(\vec{w}^T \vec{x} + b)$ $y \in \{-1, 1\}$

目标函数: $\max M \rightarrow \max \frac{2}{\|\vec{w}\|} \rightarrow \min \frac{1}{2} \|\vec{w}\|^2$

原问题:

$$\min \frac{1}{2} \|\vec{w}\|^2 \quad \text{s.t.} \quad y_i (\vec{w}^T \vec{x}_i + b) \geq 1, \quad i = 1, 2, \dots, n \quad (1)$$

其实是一个带约束的二次规划, 是凸问题, 可得最优解

二. 转化为对偶问题

上述优化问题可用拉格朗日乘子法去解:

对应的拉格朗日目标函数为:

$$L(\vec{w}, b, \vec{\alpha}) = \frac{1}{2} \|\vec{w}\|^2 - \sum_{i=1}^n \alpha_i (y_i (\vec{w}^T \vec{x}_i + b) - 1) \quad (2)$$

根据拉格朗日对偶性, 得到对偶问题的表达式:

$$L(\vec{w}, b, \vec{\alpha}) = \frac{1}{2} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i^T \cdot \vec{x}_j \quad (3)$$

加上限制条件后,


$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i^T \cdot \vec{x}_j$$

$$\text{s.t. } \alpha_i \geq 0, i=1, 2, \dots, n, \sum_{i=1}^n \alpha_i y_i = 0. \quad (4)$$

上式即为需要优化的表达式

三. 线性不可分的情况


线性可分的假设非常有局限性



四. 核函数

使用某些非线性方法, 可以得到将两个类别完美划分的曲线, 比如核函数,

让空间从线性空间变成一个更高维的空间. 在高维的线性空间下, 使用超平面进行划分



对偶问题表达式, 式(4)

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \vec{x}_i \cdot \vec{x}_j \\ \text{s.t.} \quad & \alpha_i \geq 0, i=1, 2, \dots, n, \sum_{i=1}^n \alpha_i y_i = 0. \end{aligned}$$

将红色圈中的部分进行改造

$$\text{令: } \vec{x}_i \cdot \vec{x}_j = K(\vec{x}_i, \vec{x}_j) \quad (5)$$

这个式子就是将线性空间转换到高维空间

映射到高维空间中的方法有很多种。如。

多项式核: $K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + 1)^d$

高斯核: $K(\vec{x}_i, \vec{x}_j) = \exp(-\frac{|\vec{x}_i - \vec{x}_j|^2}{2\sigma^2})$

高斯核甚至是将原始空间映射为无穷维空间。

核函数不会增加过多的计算量

五. 其他问题

1) 如何进行多分类。

主要有两种方式: 1种是 1 vs. (N-1), 2种是 1 vs. 1

第1种方法训练 N 个模型, 属于第 i 类或其他类

第2种方法训练 $\frac{N(N-1)}{2}$ 个模型, 属于第 i 类或第 j 类

2) SVM 会 overfitting 吗?

SVM 是一种不太容易 overfitting 的方法。

3) 优缺点

优点:

1. 本身是凸优化问题, 可得到全局最优解

2. 适用于线性问题和非线性问题
3. 高维样本空间的数据也能使用SVM.
因为复杂度只取决于支持向量而非所有数据
4. 理论基础比较完善.

缺点:

1. 二次规划问题将涉及 m 阶矩阵的计算
 m 为训练集的个数. 所以不适用于超大数据集
(SMO算法可缓解该问题)
2. 只适用于二分类问题, 但可以解决.